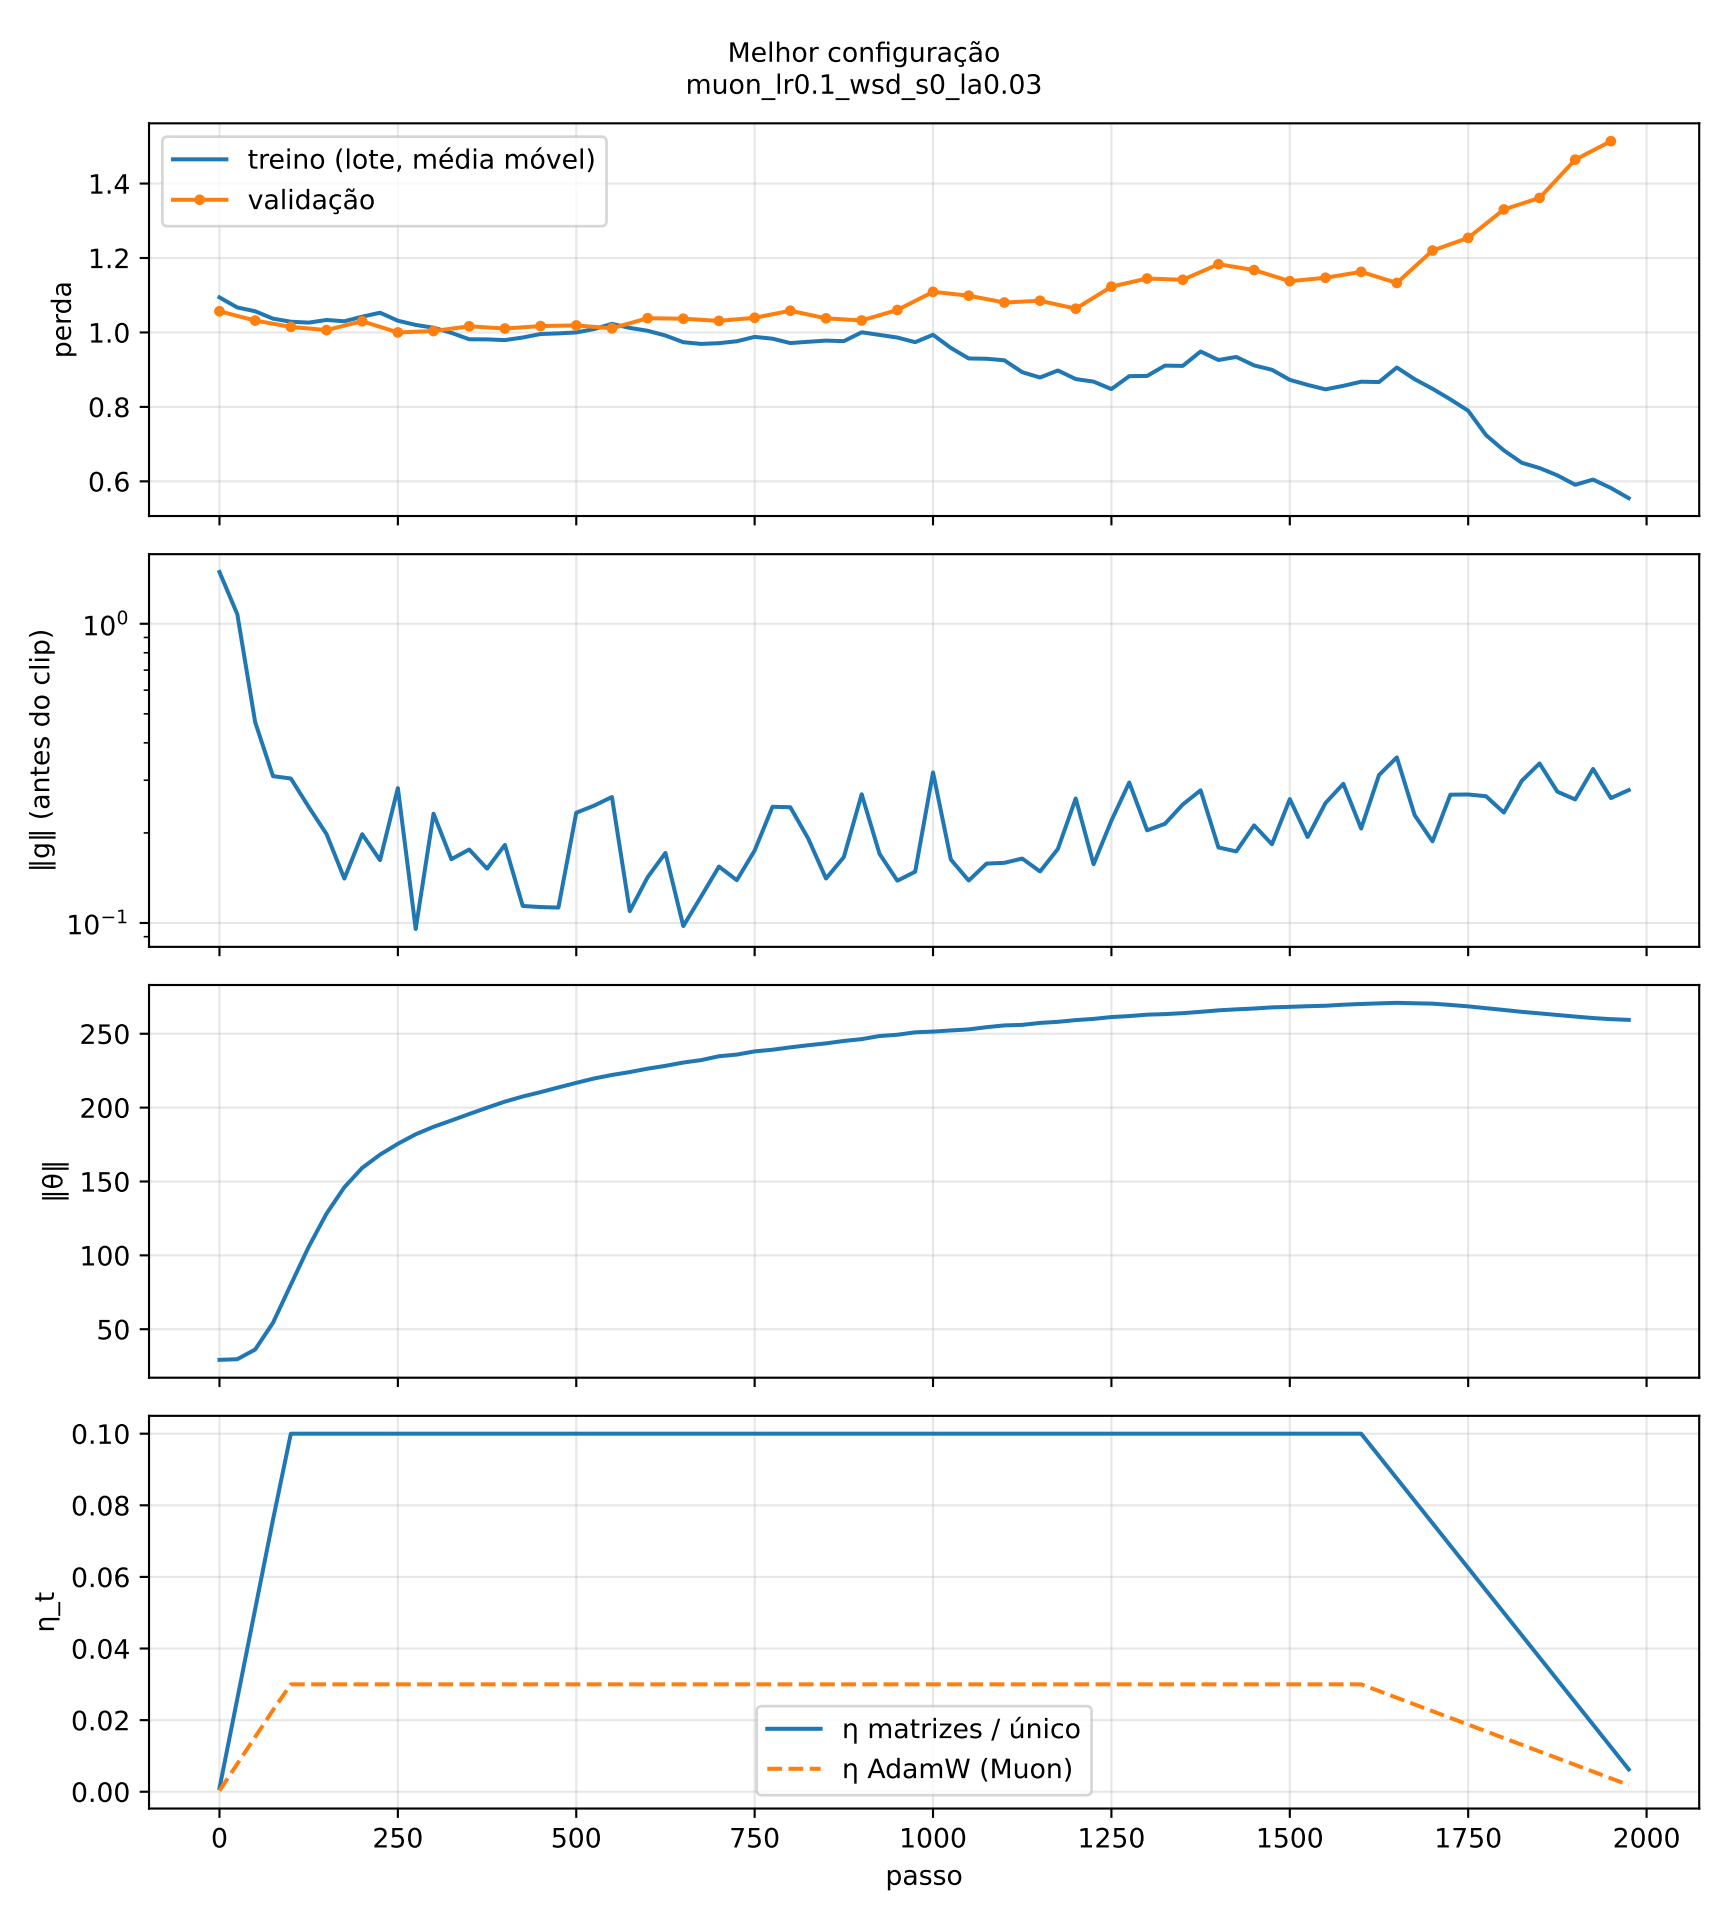
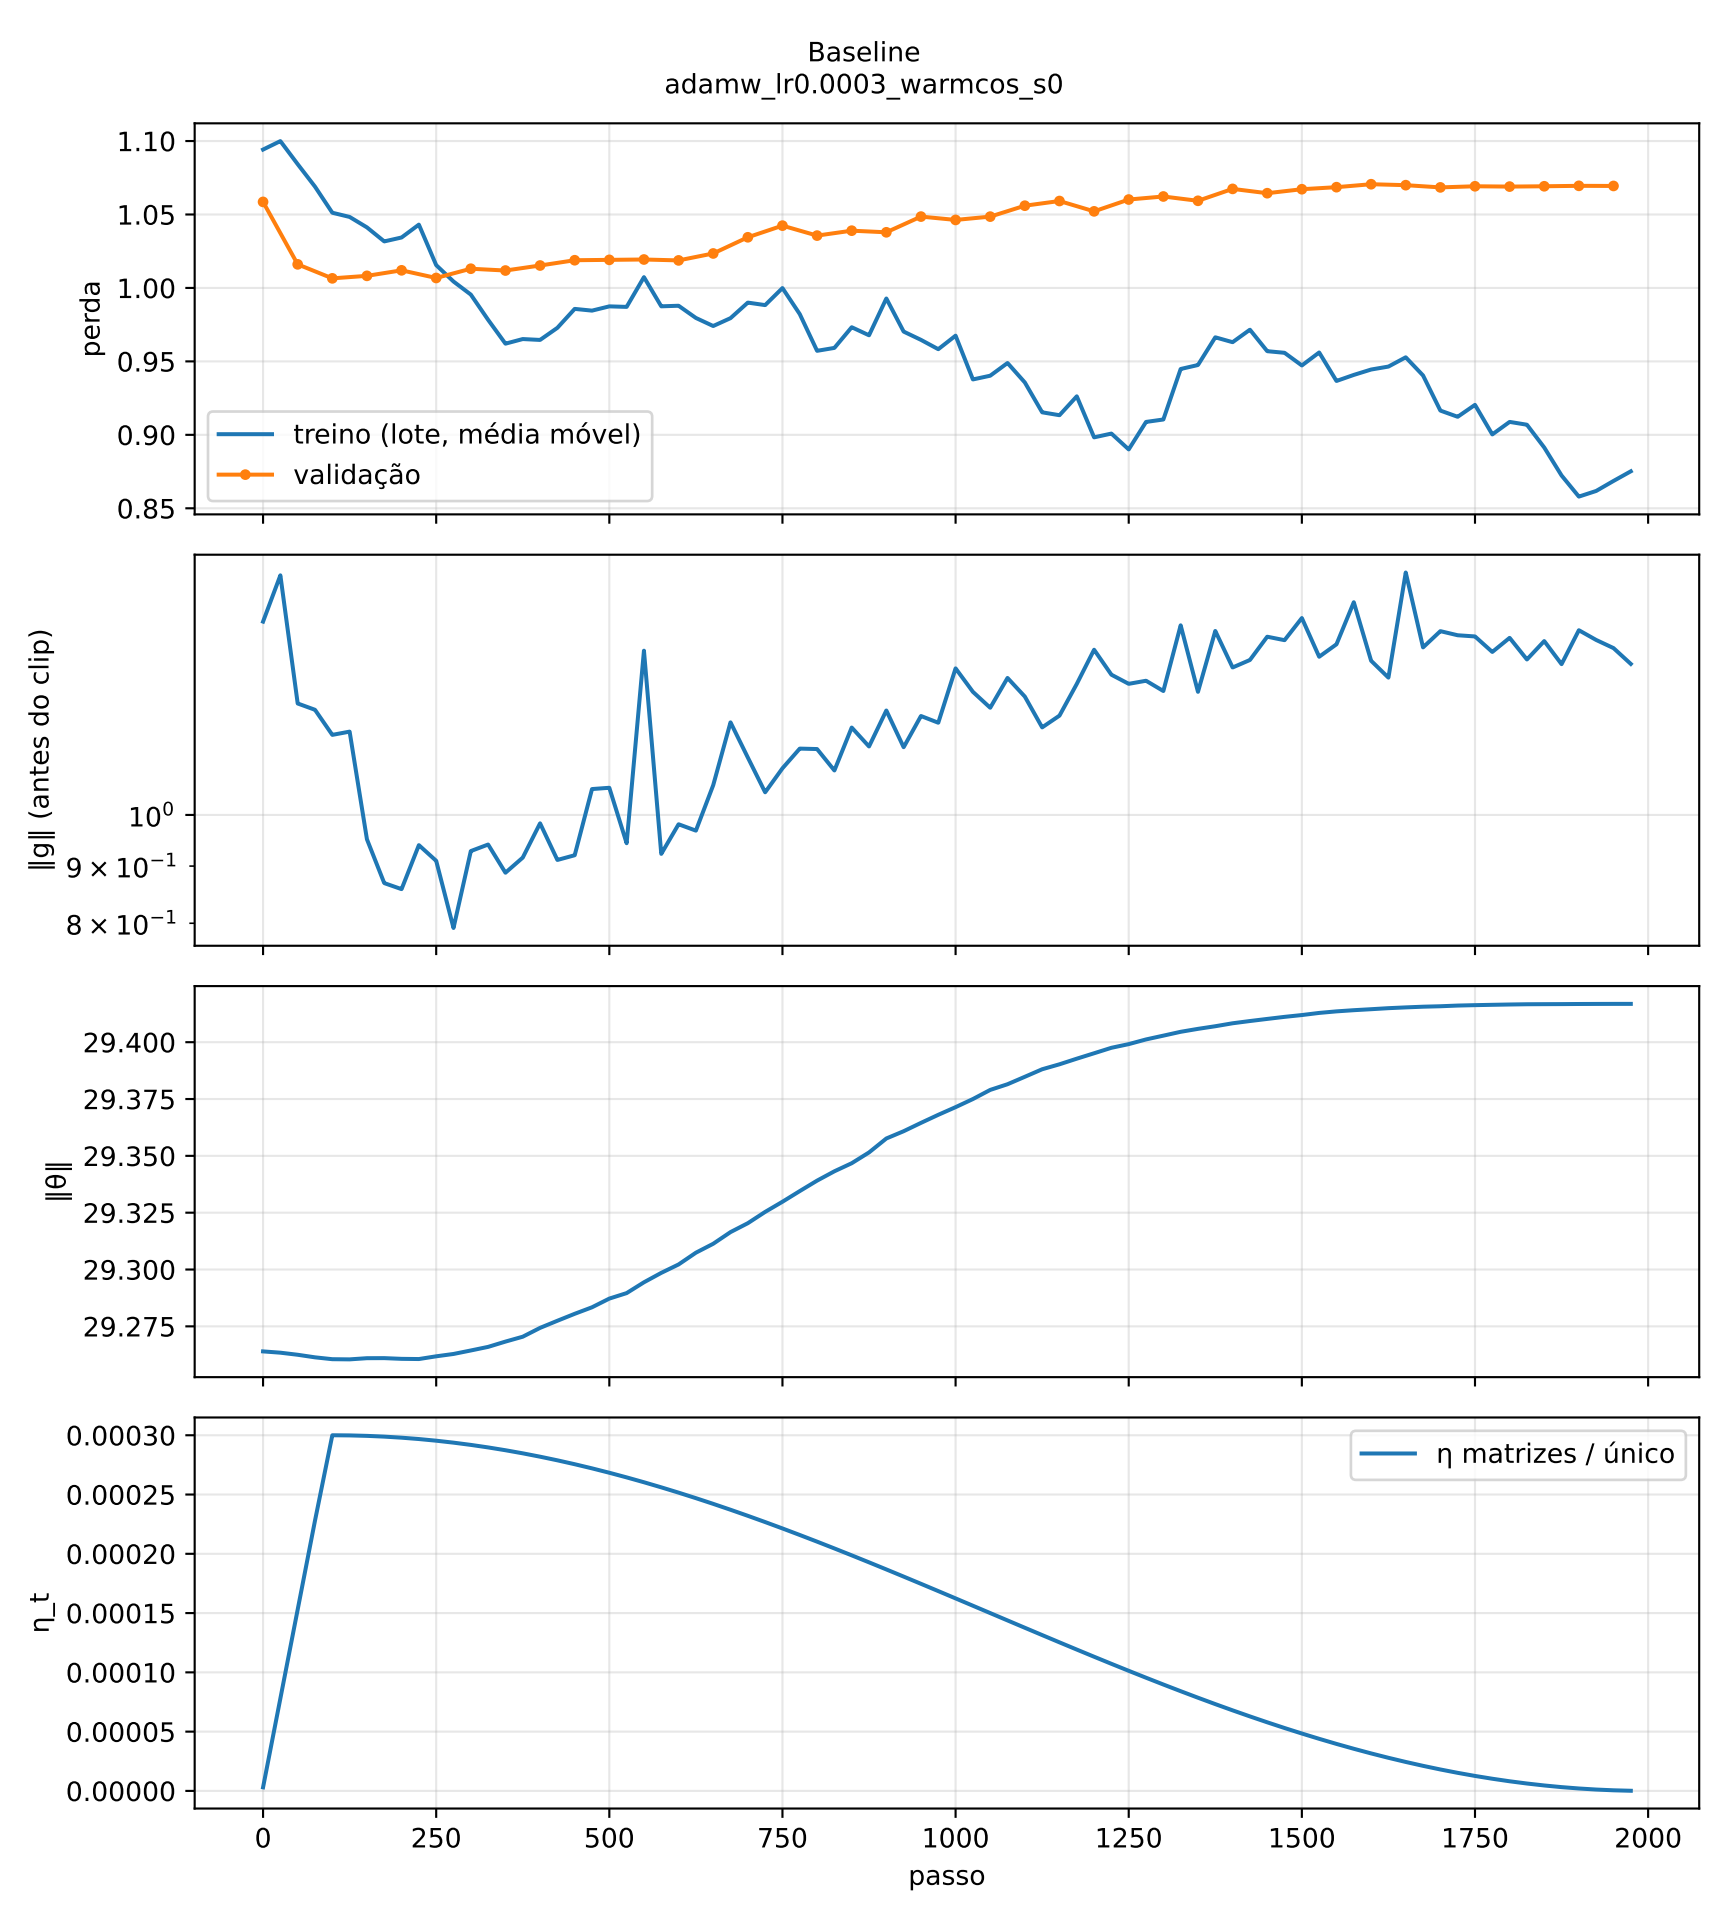
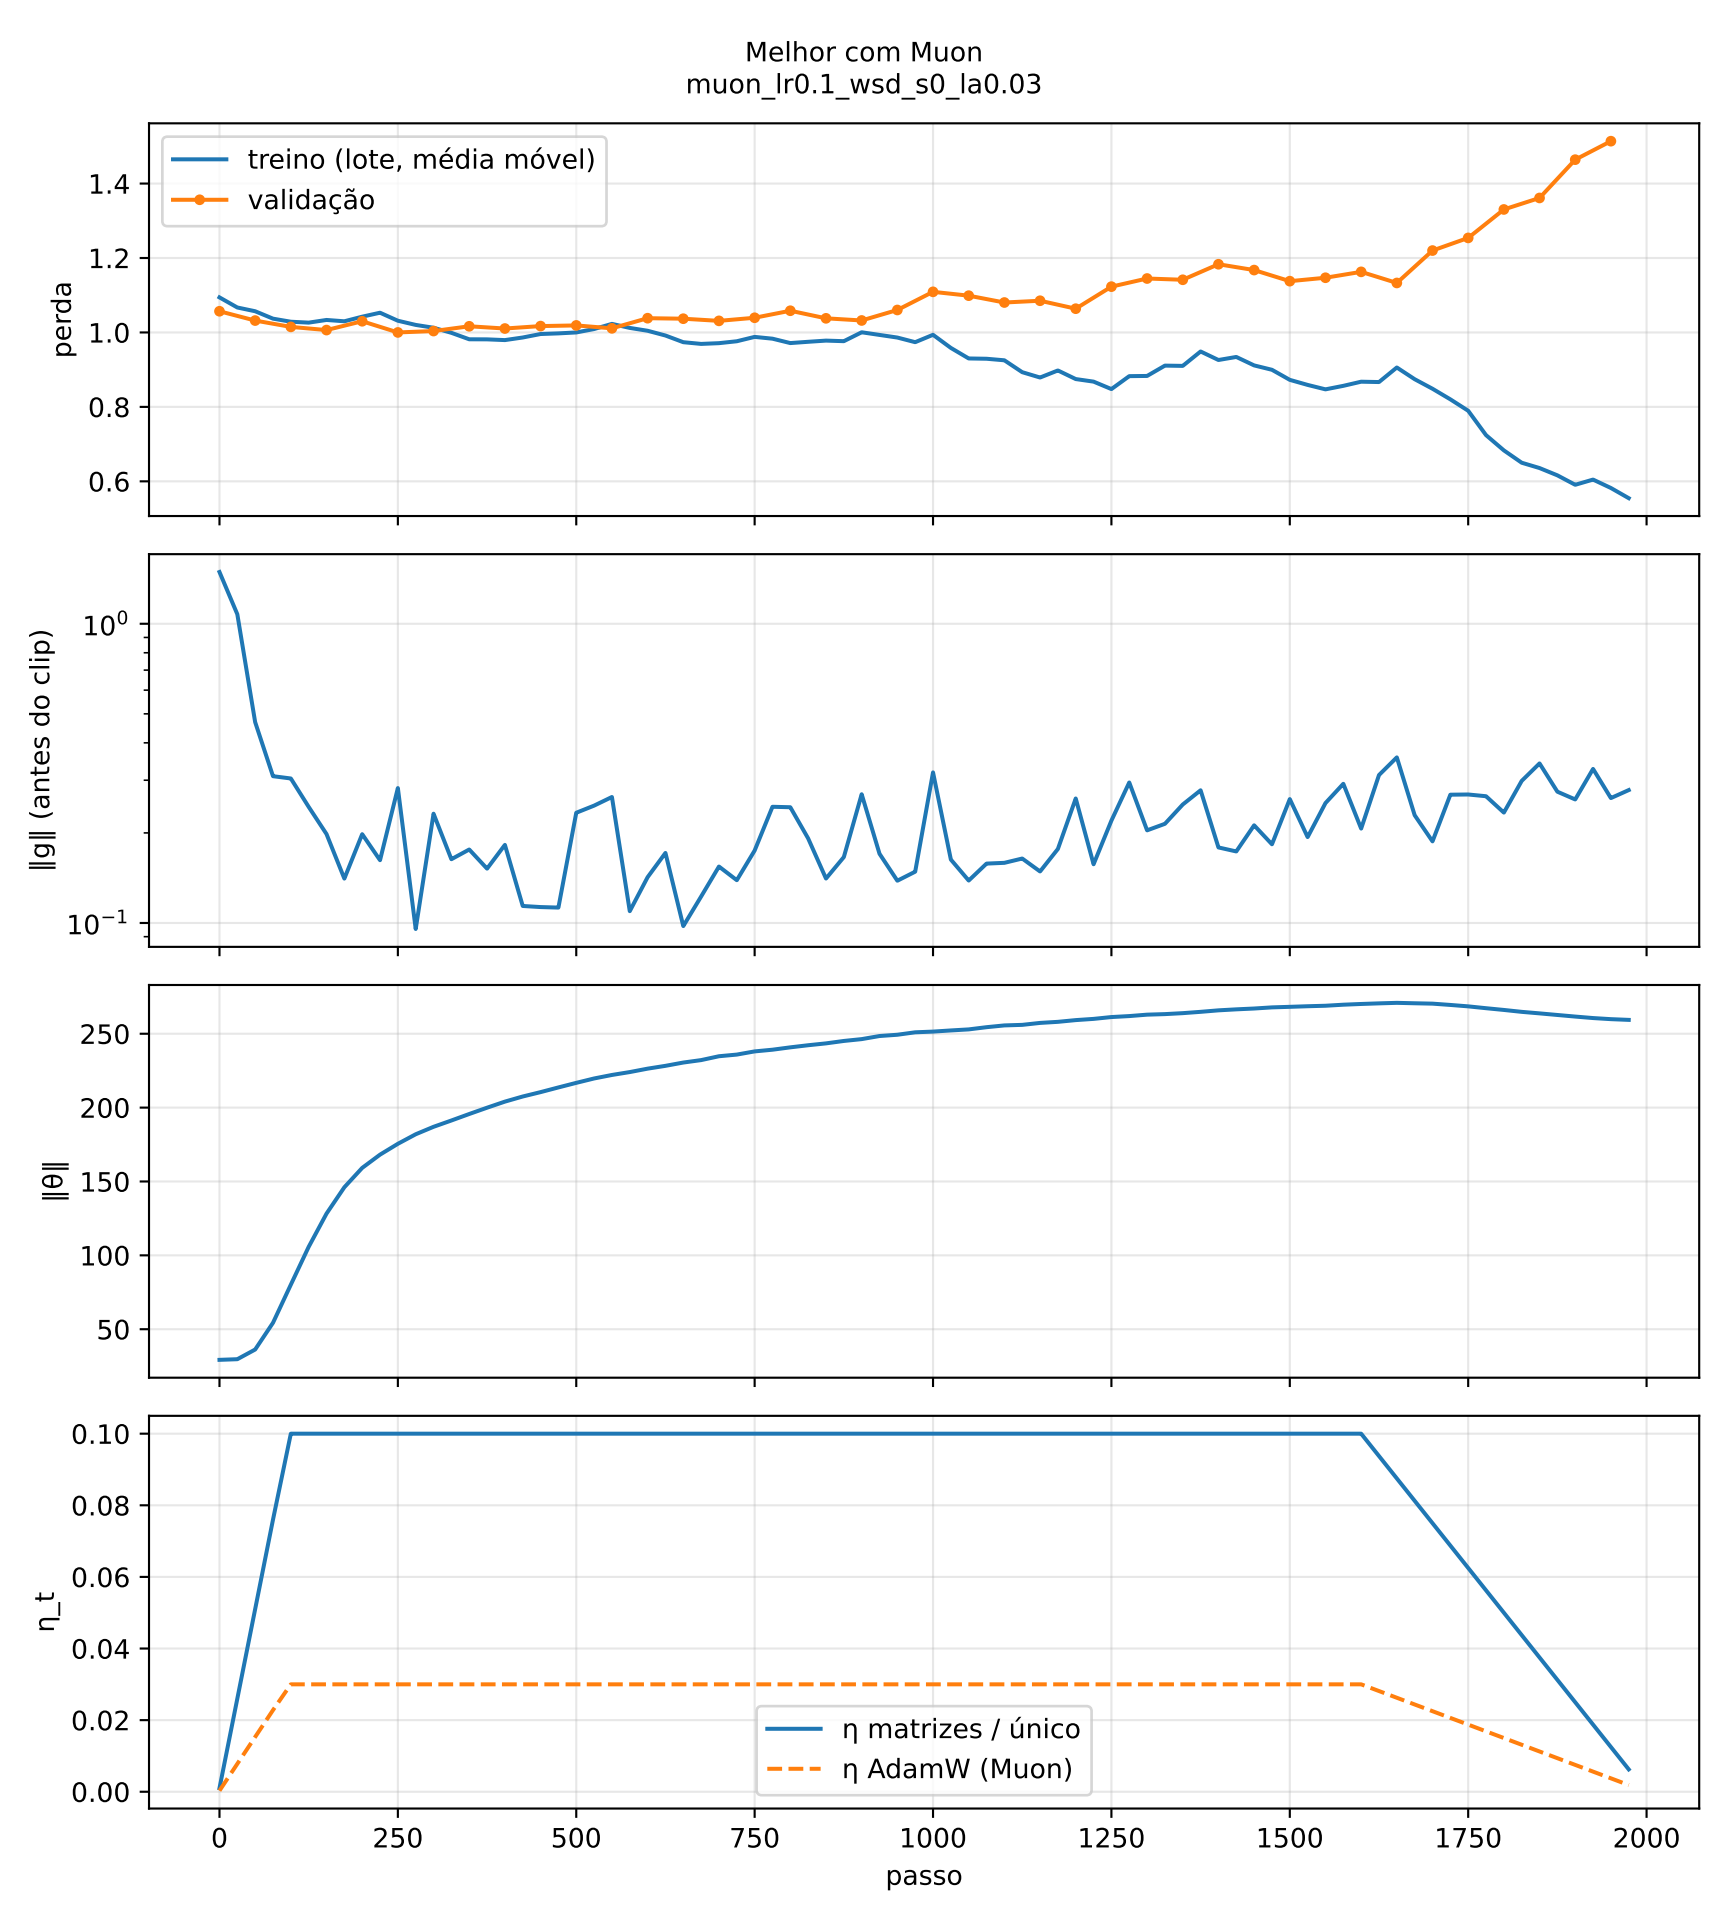
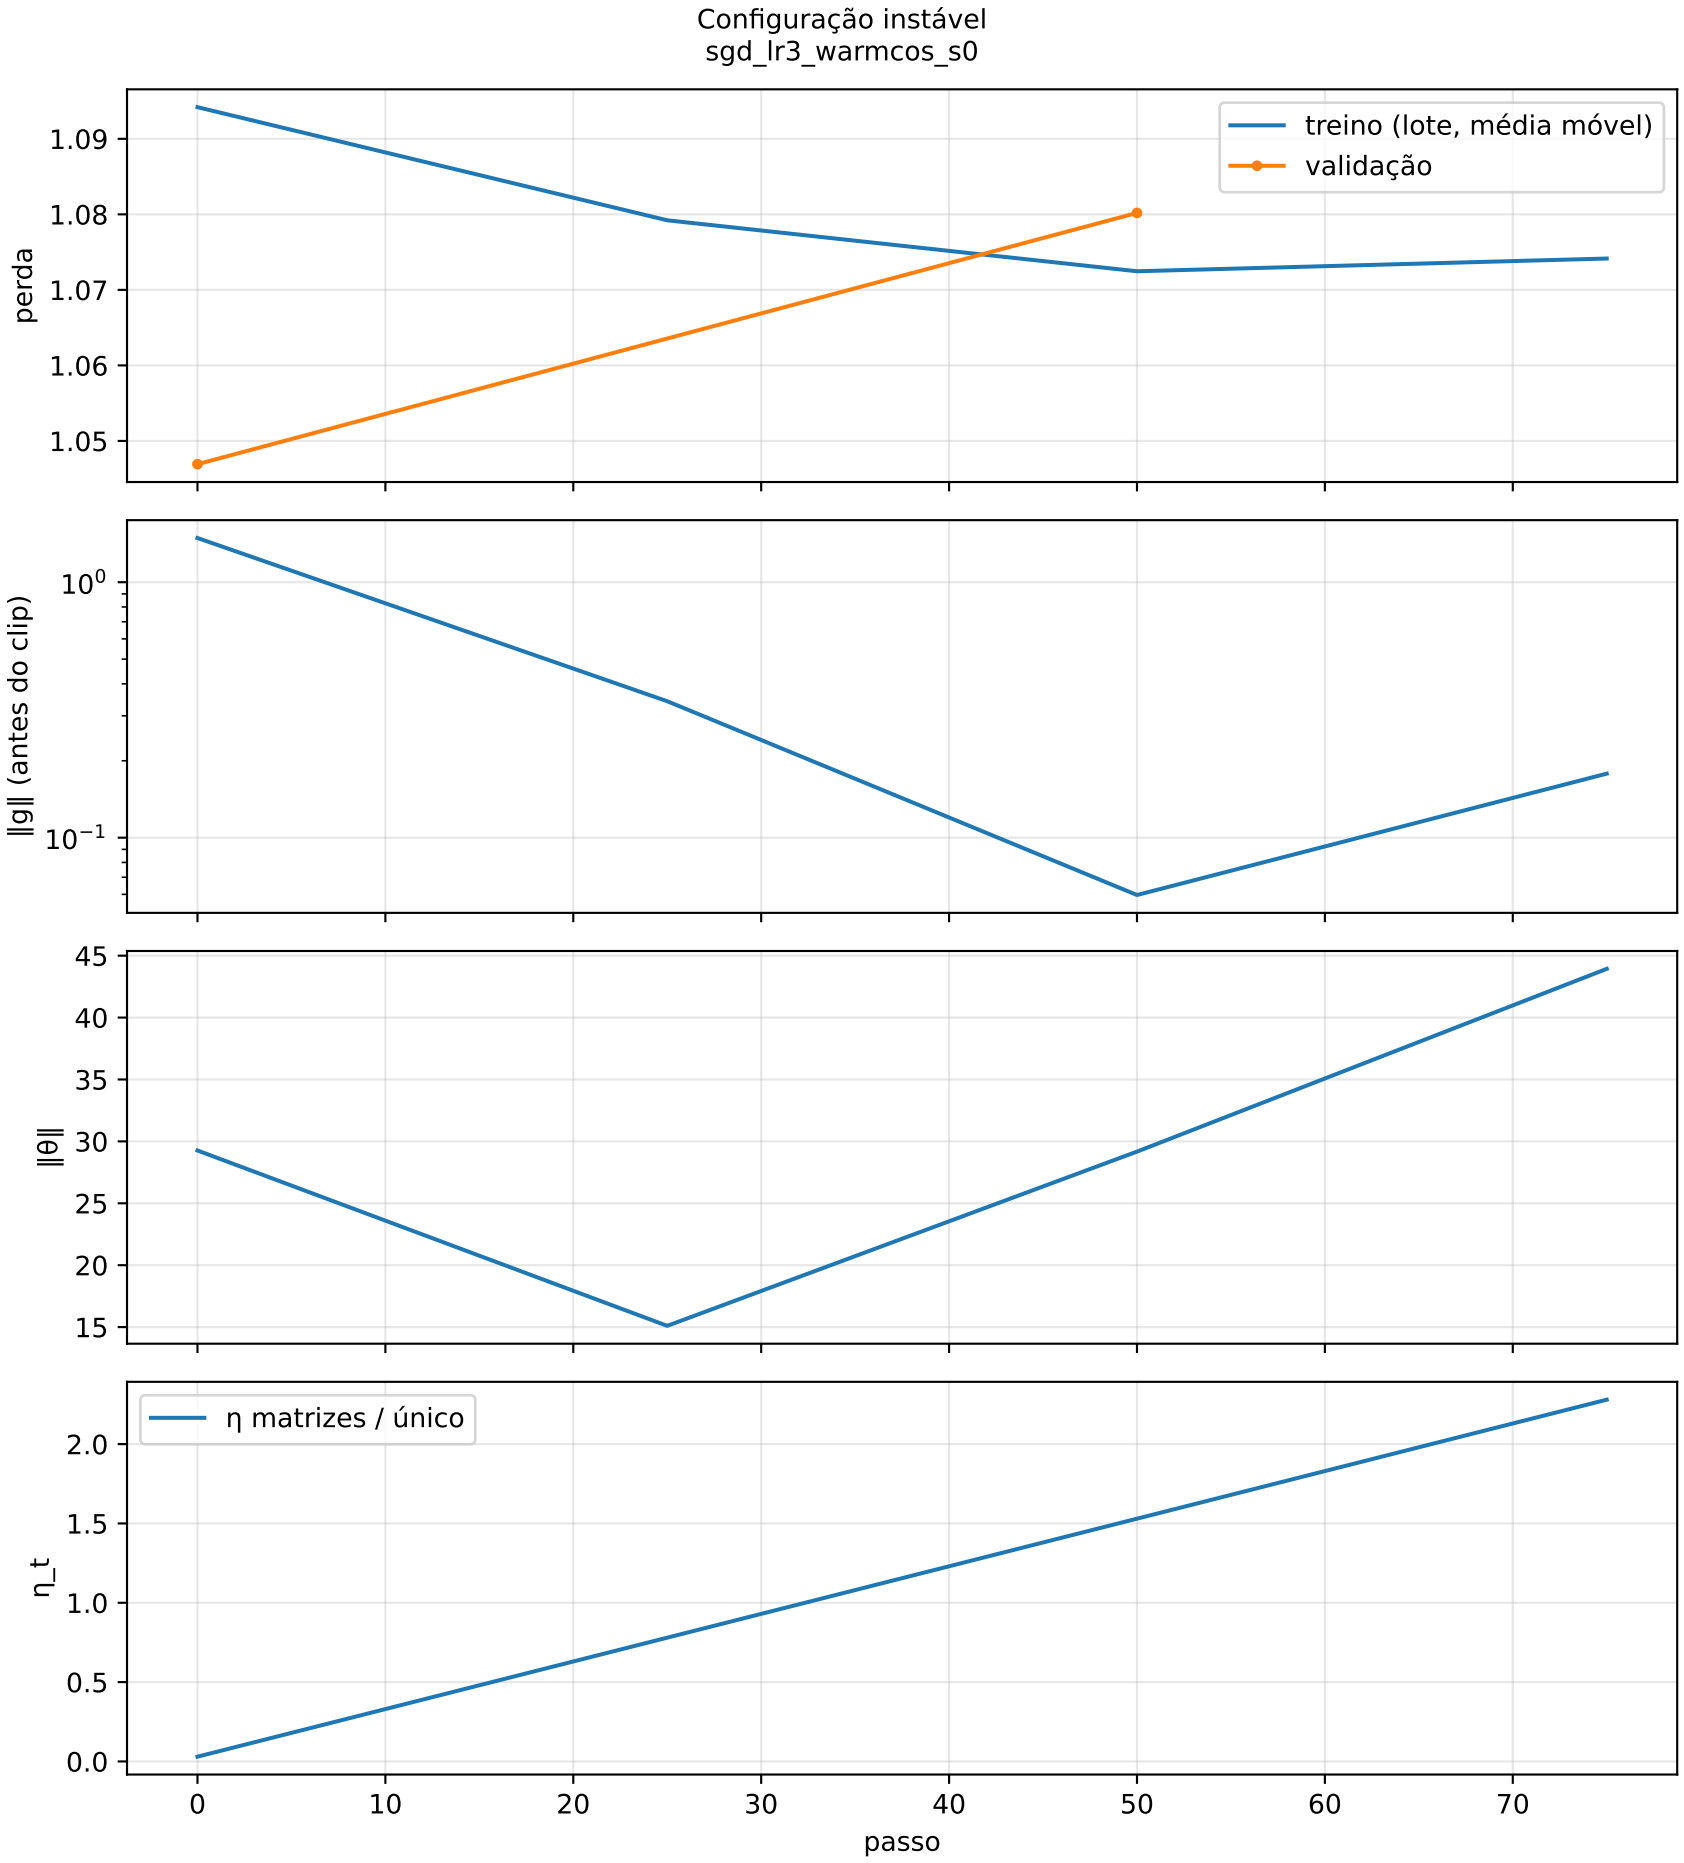
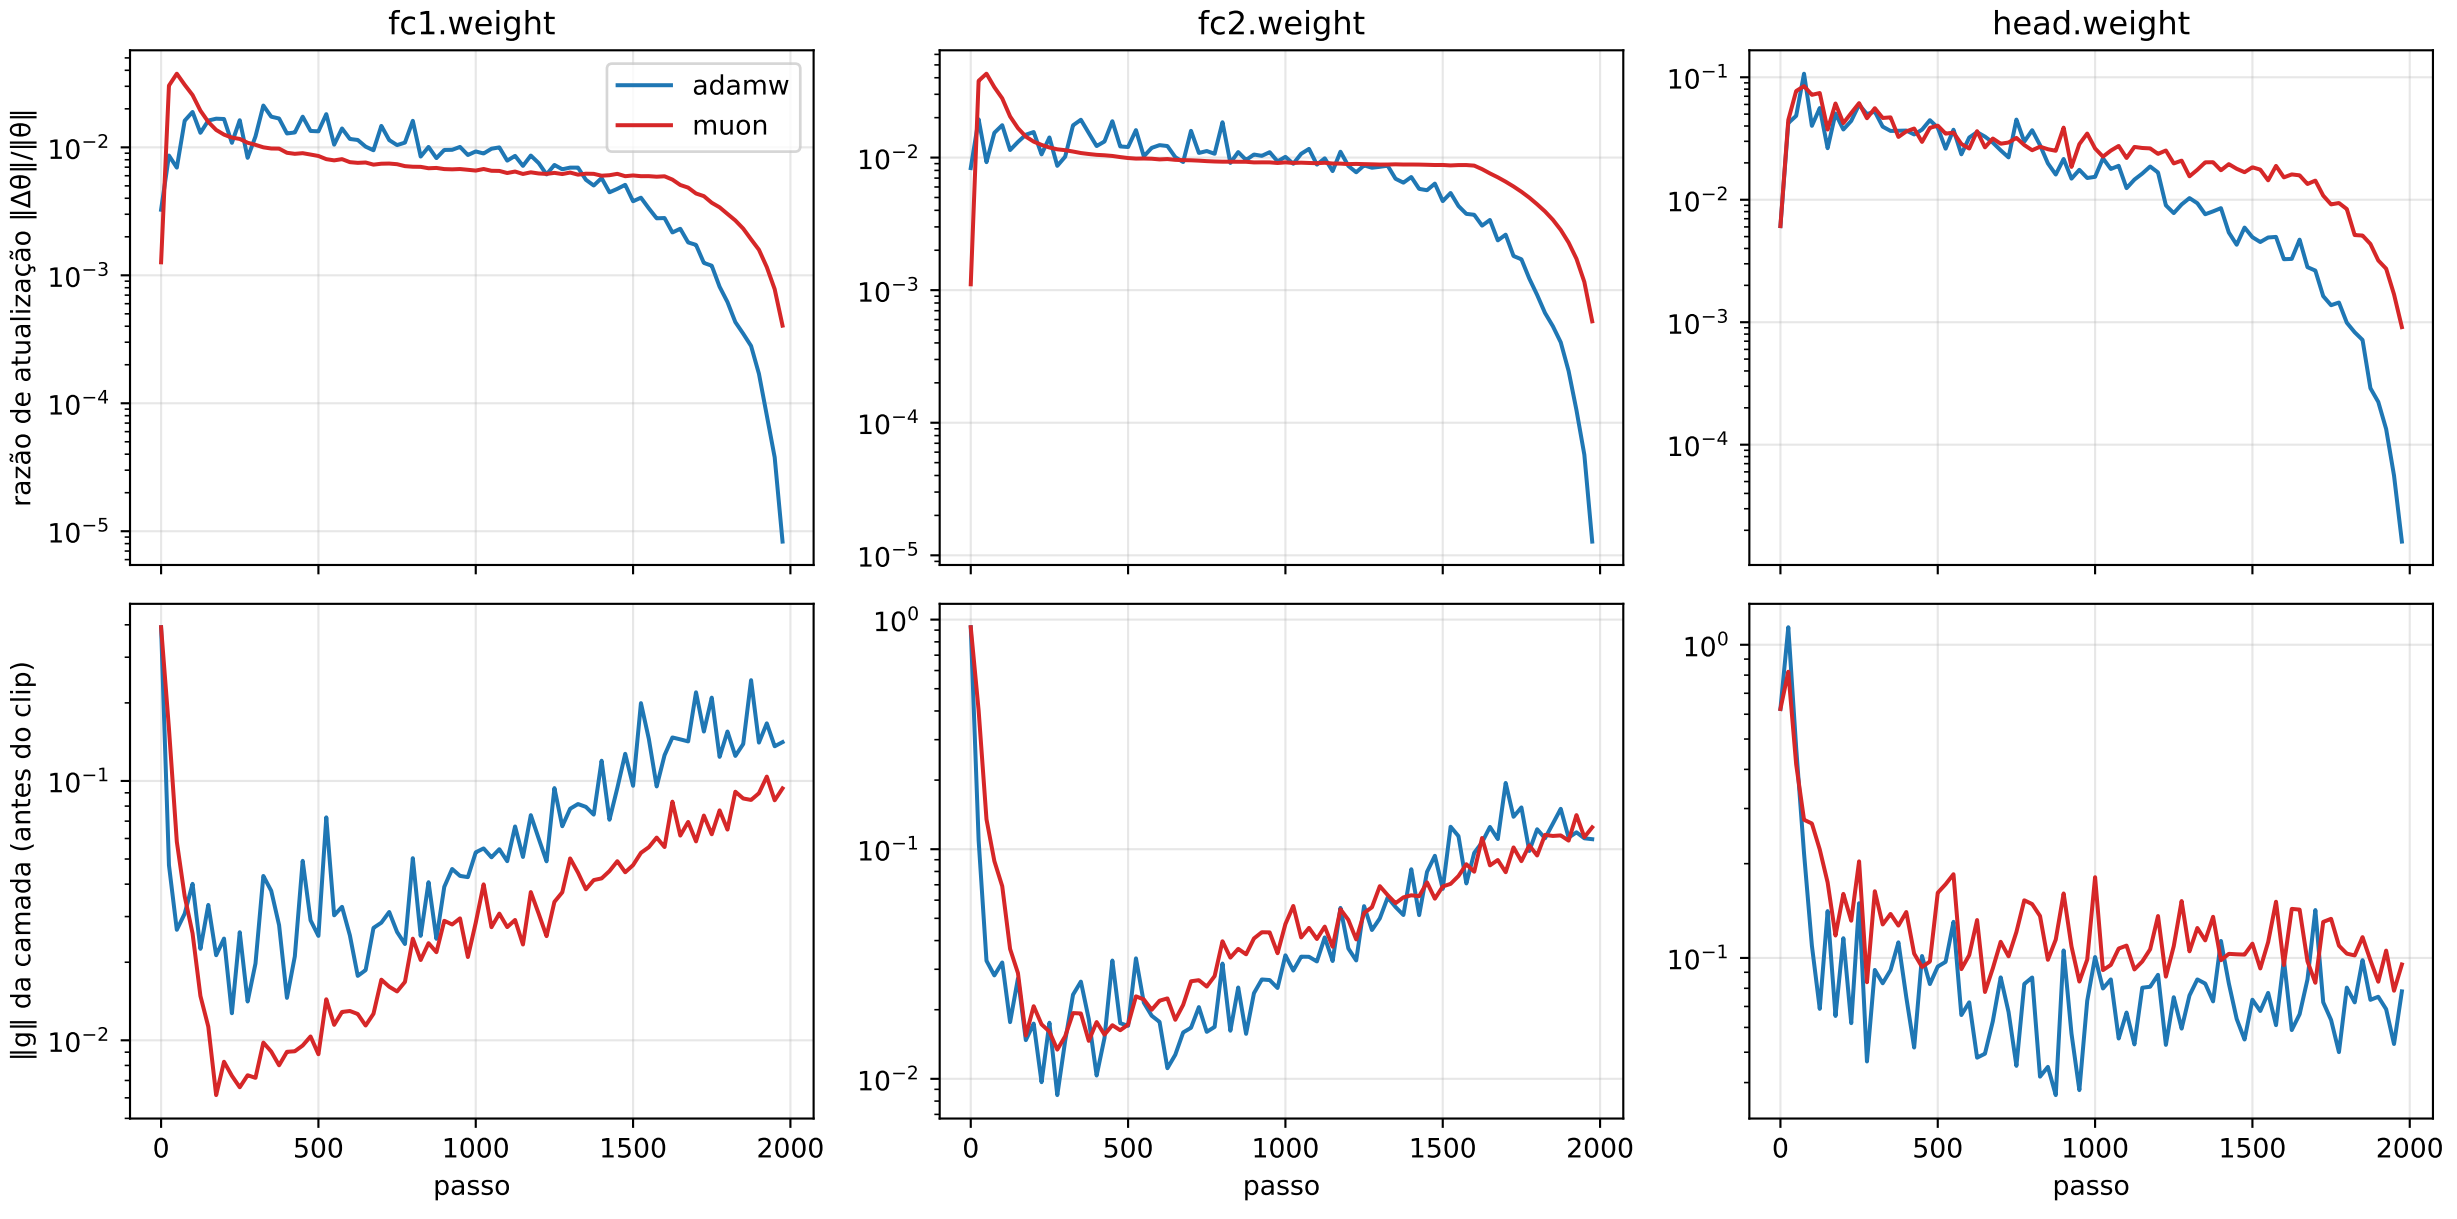
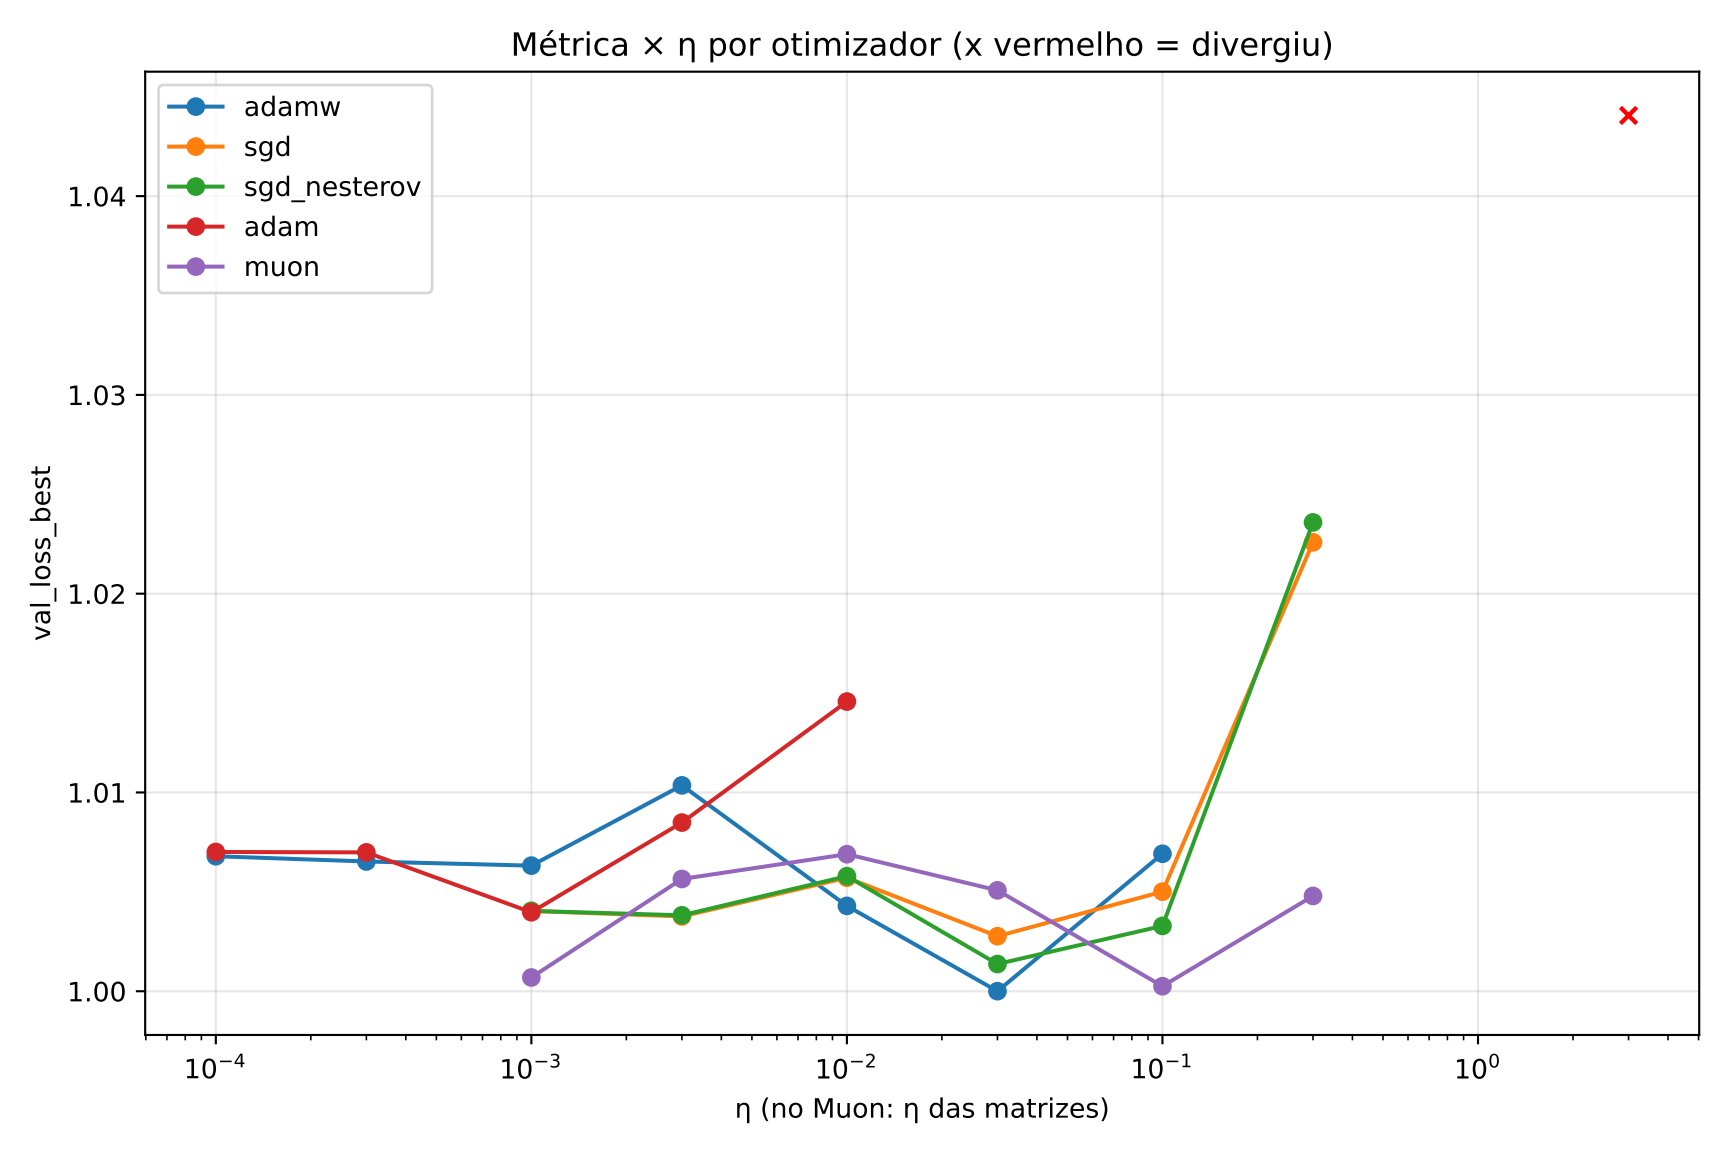

Melhor configuração
muon_lr0.1_wsd_s0_la0.03
treino (lote, média móvel)
validação
perda
1.4
1.2
1.0
0.8
0.6
‖g‖ (antes do clip)
10^{0}
10^{-1}
‖θ‖
250
200
150
100
50
η_t
0.10
0.08
0.06
0.04
0.02
0.00
η matrizes / único
η AdamW (Muon)
0
250
500
750
1000
1250
1500
1750
2000
passo


Baseline
adamw_lr0.0003_warmcos_s0
perda
treino (lote, média móvel)
validação
‖g‖ (antes do clip)
‖θ‖
η_t
η matrizes / único
passo


Melhor com Muon
muon_lr0.1_wsd_s0_la0.03
treino (lote, média móvel)
validação
perda
1.4
1.2
1.0
0.8
0.6
‖g‖ (antes do clip)
10^{0}
10^{-1}
‖θ‖
250
200
150
100
50
η_t
0.10
0.08
0.06
0.04
0.02
0.00
η matrizes / único
η AdamW (Muon)
0
250
500
750
1000
1250
1500
1750
2000
passo


Configuração instável
sgd_lr3_warmcos_s0
perda
treino (lote, média móvel)
validação
1.09
1.08
1.07
1.06
1.05
‖g‖ (antes do clip)
10^{0}
10^{-1}
‖θ‖
45
40
35
30
25
20
15
η_t
η matrizes / único
2.0
1.5
1.0
0.5
0.0
0
10
20
30
40
50
60
70
passo


Razão de atualização e gradiente por camada: AdamW × Muon
adamw_lr0.03_warmcos_s0 | muon_lr0.1_wsd_s0_la0.03
fc1.weight
fc2.weight
head.weight
adamw
muon
razão de atualização ‖ΔΘ‖/‖Θ‖
‖g‖ da camada (antes do clip)
passo
passo
passo


Métrica × η por otimizador (x vermelho = divergiu)
adamw
sgd
sgd_nesterov
adam
muon
1.04
1.03
1.02
1.01
1.00
val_loss_best
10^{-4}
10^{-3}
10^{-2}
10^{-1}
10^{0}
η (no Muon: η das matrizes)