Comparação de otimizadores no treinamento de uma rede MLP

Predição de resultados do Campeonato Brasileiro (3 classes) • mesma arquitetura e orçamento; η ajustado por otimizador

REGRAS DE ATUALIZAÇÃO DOS PESOS

SGD + momento

$v \leftarrow \mu v + g$; $\theta \leftarrow \theta - \eta \cdot v$

um único η para todos os parâmetros; sensível à escala do gradiente

SGD + Nesterov

gradiente avaliado no ponto à frente

antecipa a correção do momento em relação ao SGD

Adam

passo $\propto m / (\sqrt{v} + \varepsilon)$

η efetivo por parâmetro (adaptativo)

AdamW

Adam + decaimento de peso desacoplado

regulariza $\|\theta\|$ sem distorcer o passo adaptativo

Muon

momento → ortogonaliza (Newton–Schulz) → $U \cdot V^T$

passo uniforme em todas as direções singulares; apenas matrizes ocultas

AGENDA DA TAXA DE APRENDIZADO (warmup + cosseno)

warmup: η cresce gradualmente e evita picos de $\|g\|$ no início (estatísticas do Adam)

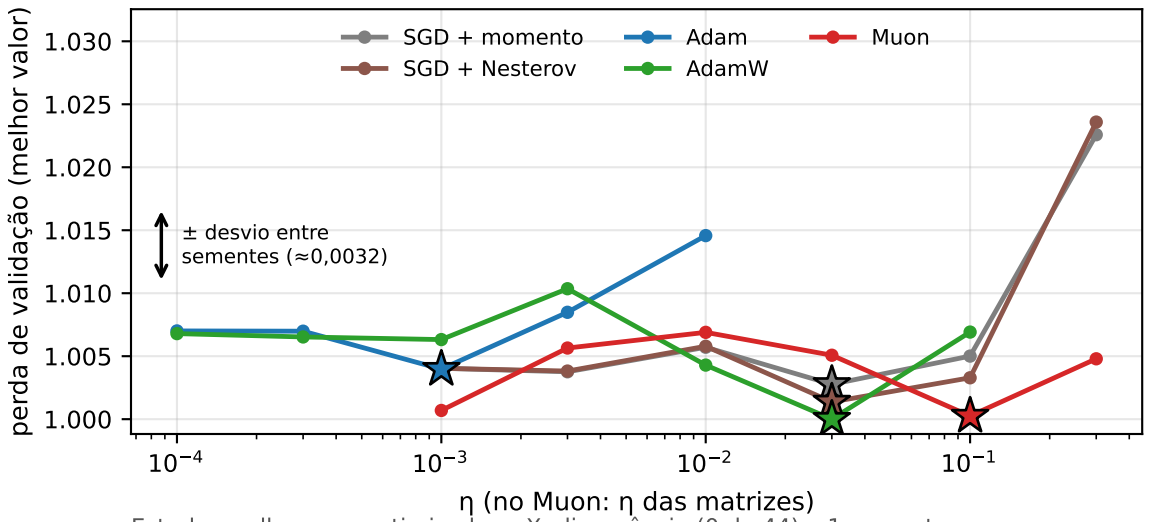
cosseno: η decresce suavemente até ≈ 0, estabilizando o treinamento no mínimo

SINAIS REGISTRADOS (a cada k passos, por camada)

perda • $\|g\|$ antes do clipping (picos: η elevado) • $\|\theta\|$ (cresce: pouca regularização)

$\rho = \|\Delta\theta\|/\|\theta\|$ (referência ≈ 1e-3) • η_t (confirma a agenda: warmup + cosseno)

DESEMPENHO: perda de validação × η (quanto menor, melhor)



Estrela: melhor η por otimizador • X: divergência (0 de 44) • 1 semente

Melhor configuração: Muon, η = 0,1, wsd: perda 1,0027 ± 0,0027
Baseline (adamw, η = 0,0003): 1,0098 ± 0,0028; ganho +0,0071 > desvio entre sementes
1º × 2º (AdamW): Δ = 0,0010; inferior ao desvio: empate técnico
Melhor passo mediano: 300/2000; perda de validação final ≈ 1,07 (sobreajuste)

MECANISMO DE COMPARAÇÃO (protocolo)

1 Ajuste de η

grade logarítmica (≥ 5 valores) com agenda fixa

2 Agendas

constante, cosseno, warmup + cosseno e WSD

3 Confirmação

3 melhores combinações, 3 sementes, mesmo orçamento

4 Decisão

vencedor somente se a diferença superar o desvio entre sementes

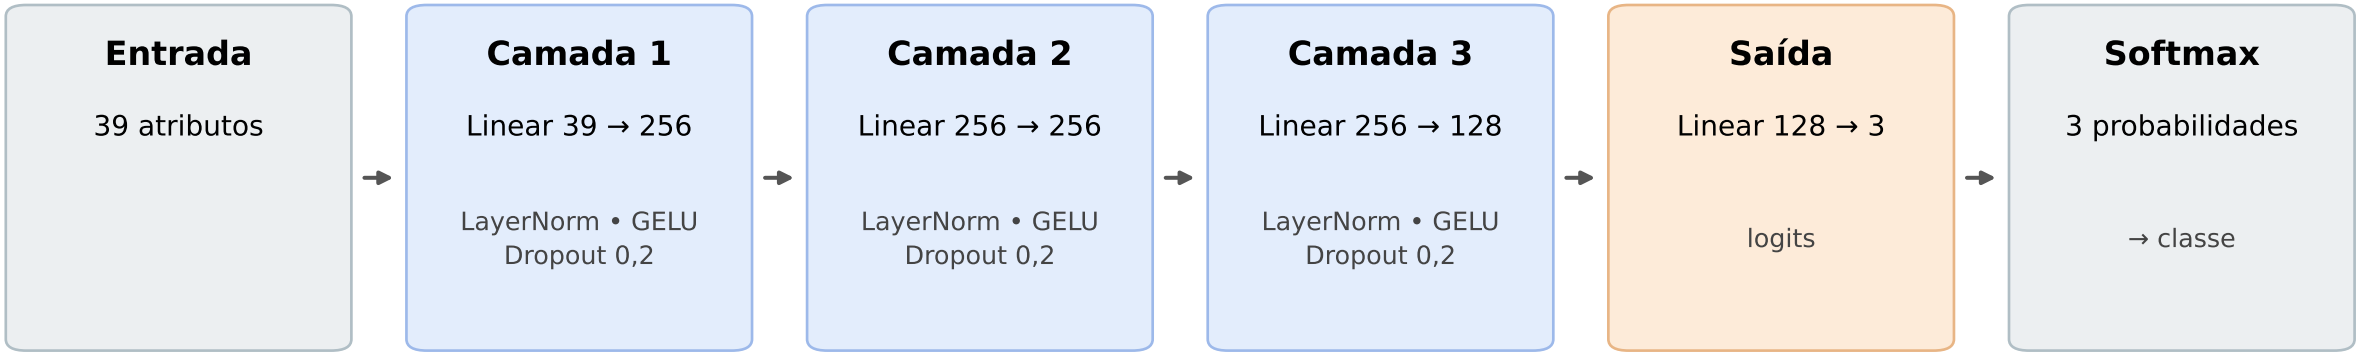
Teste (2021+) utilizado uma única vez • todas as execuções reportadas

Leitura: picos de $\|g\|$ → reduzir η ou clipping • ρ ≲ 1e-5 → aumentar η
$\|\theta\|$ crescente sem estabilização → aumentar o weight decay

Arquitetura da rede neural (MLP) e função de erro

Entrada: 39 atributos (forma recente, Elo e descanso) • Saída: vitória do mandante, empate ou vitória do visitante

4 camadas lineares (3 ocultas + saída) • as matrizes fc1, fc2 e fc3 são otimizadas pelo Muon; saída, vieses e LayerNorm, pelo AdamW



Função de erro: entropia cruzada

$L = -\log p(\text{classe correta})$

logits → softmax → probabilidades

penaliza previsões confiantes e erradas

classificador uniforme: $\ln 3 \approx 1{,}10$

menor perda de validação obtida ≈ 1,00

Função de ativação: GELU

$\text{GELU}(x) = x \cdot \Phi(x)$

curva suave (a ReLU tem ponto angular em 0)

gradiente contínuo, favorável ao

Adam e ao Muon

aplicada após cada LayerNorm

Normalização e regularização

LayerNorm: normaliza cada exemplo

Dropout de 0,2: reduz o sobreajuste

decaimento de pesos (weight decay) de 0,01

limitação do gradiente (clipping) em 5,0

orçamento fixo: lote 128, 2000 passos

110.595 parâmetros • 5.947 partidas de treinamento • 1.016 de validação • 1.245 de teste (2021 em diante)

Divisão temporal: o modelo não utiliza partidas futuras no treinamento

Interpretação dos sinais registrados no treinamento

Perda, ‖g‖, ‖θ‖, razão de atualização ρ e η_t, alinhados no mesmo eixo de passos

LEITURA DE CADA SINAL

Perda (treino e validação)

treino decrescente com validação crescente indica sobreajuste, e não instabilidade

‖g‖ antes do clipping

picos indicam η excessivo; valor ≈ 0 no início indica gradiente evanescente

‖θ‖

crescimento sem estabilização indica regularização insuficiente (weight decay)

ρ = ‖Δθ‖/‖θ‖ por camada

referência ≈ 1e-3; ≲ 1e-5: passo pequeno; ≳ 1e-1: oscilação

η_t

confirma a agenda: warmup crescente seguido de decaimento por cosseno

OBSERVAÇÕES NESTE EXPERIMENTO

Melhor passo mediano: 300 de 2000

Perda de validação final (mediana): 1,07; Muon: 1,68

Execuções divergentes: 0 de 44

η ótimo: Adam 0,001 • AdamW 0,03 • Muon 0,1
SGD 0,03 • Nesterov 0,03

DADOS DO PAINEL (melhor execução, semente 0)

Valores indisponíveis: execute python slide.py na pasta que contém logs/ para preencher ‖g‖, ‖θ‖ e ρ.

DIAGNÓSTICO

Sobreajuste, e não instabilidade: a perda de validação atinge o mínimo precocemente e depois cresce, enquanto a de treino continua decrescendo.

Por isso adota-se o ponto de menor perda de validação (parada antecipada); a diferença entre os melhores otimizadores permanece dentro do ruído entre sementes: o ganho decorre do ajuste de η e da agenda, e da parada no momento adequado.