Qual otimizador treina melhor a rede do Brasileirão?

MLP 3 classes (mandante / empate / visitante) • mesma rede, mesmo orçamento, η ajustado para cada otimizador

COMO CADA UM ATUALIZA OS PESOS

SGD + momento

$v \leftarrow \mu v + g$; $\theta \leftarrow \theta - \eta \cdot v$

um único η para todos os pesos; sensível à escala

SGD + Nesterov

gradiente avaliado no ponto à frente

corrige o momento mais cedo que o SGD

Adam

passo ∝ m / (√v + ε)

η efetivo por parâmetro (adaptativo)

AdamW

Adam + decaimento de peso desacoplado

regulariza ‖θ‖ sem distorcer o passo

Muon

momento → ortogonaliza (Newton–Schulz) → $U \cdot V^T$

mesmo passo em toda direção singular; só matrizes ocultas

AGENDA DE η (warmup + cosseno)

warmup: η sobe devagar e evita picos de ‖g‖ no início (estatísticas do Adam)

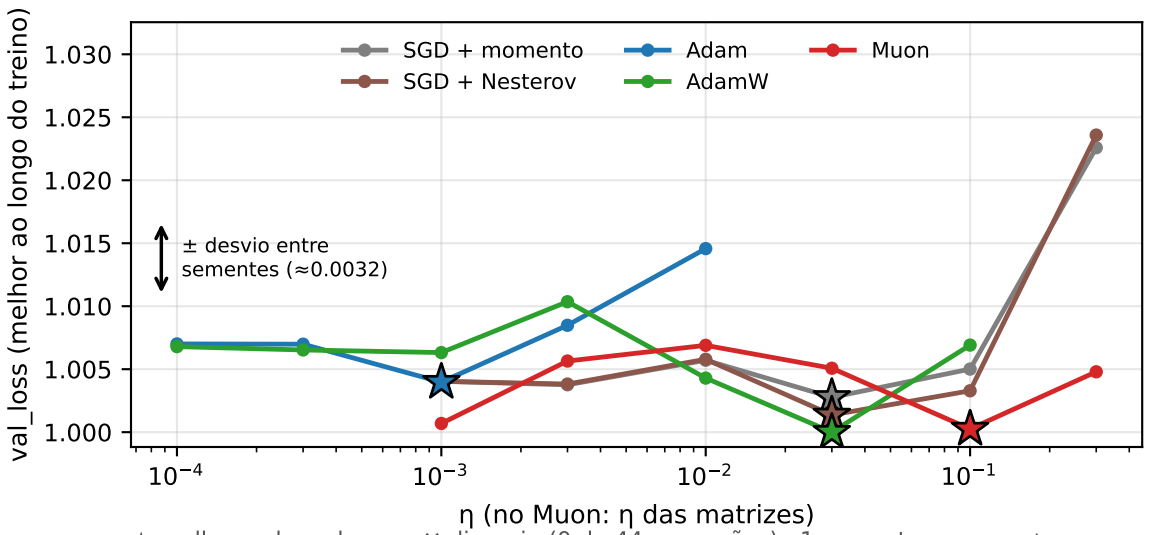
cosseno: η cai suave até ~0 e o treino "assenta" no vale

SINAIS REGISTRADOS (a cada k passos, por camada)

perda • ‖g‖ antes do clip (picos = η grande) • ‖θ‖ (cresce = falta weight decay)

ρ = ‖Δθ‖/‖θ‖ (≈1e-3 é boa referência) • η_t (confirma a agenda: warmup + cosseno)

DESEMPENHO: perda de validação × η (menor é melhor)



★ melhor η de cada um × divergiu (0 de 44 execuções) 1 semente, warmup+cosseno

Melhor: Muon, η=0.1, wsd → val_loss 1.0027 ± 0.0027

Baseline adamw (η=0.0003): 1.0098 ± 0.0028 • ganho +0.0071 > desvio ✔

1º × 2º (AdamW): Δ=0.0010 < desvio → empate técnico

Melhor passo mediano: 300/2000 • val_loss no fim ≈ 1.07 → sobreajusta

MECANISMO DE COMPARAÇÃO (protocolo justo)

1 Ajustar η

grade log ≥5 η, agenda fixa; borda → estender

2 Agendas

const, cosseno, warmup+cosseno, WSD

3 Confirmar

3 melhores combos com 3 sementes, mesmo orçamento

4 Decidir

vence só se Δ > desvio entre sementes

Teste (2021+) usado uma só vez • tudo reportado, inclusive divergências

Leitura: ‖g‖ com picos → η menor ou clipping • ρ ≲ 1e-5 → η maior

‖θ‖ sobe sem parar → mais weight decay